ING. CIENCIA DE DATOS Y MATEMÁTICAS

Sesión 02: Arquitecturas Avanzadas para Secuencias de Largo Aliento

Módulo de Modelos y TDA

Desarrollo de Proyectos de Ingeniería Matemática

El Problema Detonador

Escenario: "El Auditor de Reportes Anuales"

Retomamos el desafío de nuestra startup financiera, pero elevamos drásticamente la dificultad computacional.

El modelo ahora debe analizar **Reportes Anuales de 50 páginas** (miles de palabras).

El Objetivo: Detectar señales sutiles de fraude contable. La particularidad es que el preámbulo engañoso se menciona en las primeras páginas y se confirma implícitamente mediante una anomalía 50 páginas después.



El Conflicto Computacional

La "Amnesia" de la RNN Vanilla

En la sesión anterior demostramos el colapso matemático al enfrentar más de 10-20 pasos temporales.

Si la señal de fraude está separada por 500 párrafos, ocurre un fallo catastrófico en la asignación de crédito a través del tiempo.

Gradiente Desvaneciente

Al aplicar Backpropagation Through Time (BPTT), la señal de error penalizadora es multiplicada repetidamente por el Jacobiano.

La señal se encoge exponencialmente, llegando casi a cero en los primeros pesos.

Pregunta: ¿Cómo podemos diseñar un "canal de flujo libre"?

La Solución Matemática

Long Short-Term Memory (LSTM)

Rediseñando la topología para permitir la supervivencia de la información a largo plazo mediante compuertas neuronales.

El Estado de la Celda y Compuertas

Rompiendo la "Caja Negra"

Una LSTM es un sistema de ecuaciones diferenciales discretas con bucles de auto-retroalimentación (Self-loops).

El Estado de la Celda: La innovación central. Actúa como una "supercarretera" de datos. Es un camino lineal a través del cual la información puede fluir con cambios mínimos u operaciones lineales simples.

El flujo en esta autopista está regulado por compuertas. La primera es la **Compuerta de Olvido**, que decide matemáticamente qué información debe descartarse mediante una función sigmoide (valores entre 0 y 1).

$$f_t = \sigma (b_f + U_f x_t + W_f h_{t-1})$$

Mecánica de Compuertas (Gating)

1. Compuerta de Olvido

Controla cuánta memoria pasada del estado de la celda conservamos. Si el valor es cercano a 0, la red "olvida" el contexto anterior. Fundamental para mitigar la saturación de información.

2. Compuerta de Entrada

Decide qué porción de la nueva información observada en el paso actual merece entrar al estado de la celda (la supercarretera). Actúa como un filtro de relevancia de corto plazo.

3. Compuerta de Salida

Filtra qué parte del estado interno modificado se mostrará al resto de la red (y a la siguiente iteración) como el nuevo estado oculto final.

Eficiencia y Simplificación: GRU

Gated Recurrent Unit

Presentamos la GRU como una versión optimizada que busca reducir el costo computacional de la LSTM sin perder sustancialmente capacidad de representación matemática.

- **Fusión de Estados:** A diferencia de la LSTM, la GRU elimina la celda independiente y combina la memoria a largo y corto plazo en un solo vector.

Las Dos Compuertas GRU

- **Update Gate:** Actúa como un integrador con fugas condicional. Decide dinámicamente si copiar el estado anterior intacto o actualizarlo con el nuevo valor objetivo propuesto.
- **Reset Gate:** Controla agresivamente qué partes del estado pasado se utilizan para calcular la siguiente propuesta de estado candidato.

Comparativa Técnica (Duelo de Arquitecturas)

Característica	Long Short-Term Memory (LSTM)	Gated Recurrent Unit (GRU)
Complejidad	Mayor (3 compuertas explícitas)	Menor (2 compuertas combinadas)
Parámetros	Más pesada computacionalmente	Más eficiente y rápida de entrenar
Control de Flujo	Olvido y entrada operan independientemente	Olvido y actualización fuertemente acoplados
Rendimiento	Crítica la "compuerta de olvido" con sesgo inicial de 1	Altamente competitiva, a menudo iguala a la LSTM empíricamente

Implementación en PyTorch

De la Teoría a la Praxis

Integrando `torch.nn` en nuestro flujo.

- **Uso de nn.LSTM:** Al invocar este módulo, el retorno es una tupla: `(output, (h_n, c_n))`. Es vital entender que `c_n` representa directamente la memoria a largo plazo al final de la secuencia.
- **Métricas de Evaluación:** Abandonaremos la simple Accuracy para lidiar con el desbalance (fraudes raros). Implementaremos **F1-Score**.
- **Monitor de Gradiente:** Evaluaremos la norma del gradiente iterativamente para verificar científicamente que el desvanecimiento ha sido mitigado.



Resolución del Problema (Actividad)

El Desafío en Clase

Modificar el código del laboratorio anterior reemplazando la arquitectura `CustomRNN` fallida por `nn.LSTM`.

Entrenarán el nuevo modelo con el dataset de "Noticias Financieras Largas" forzando un SEQ_LENGTH = 500 pasos temporales.

Análisis Crítico Final

Al observar los resultados, deberán formular una hipótesis matemática para la siguiente pregunta:

¿Por qué la LSTM logra un F1-score superior a 0.90 mientras que la RNN Vanilla se estancó en 0.54?

Reflexión: Con esto formarán criterio para decidir cuándo la complejidad matemática de una LSTM se justifica frente a la eficiencia pura de una GRU.

Image Sources



https://images.template.net/generator-images/0-ai-presentation-generator/Annual%20Report%20Presentation-0.webp

Source: www.template.net



https://www.dataexpertise.in/wp-content/uploads/2025/05/istockphoto-2192134048-1024×1024-1-696×522.jpg

Source: www.dataexpertise.in



https://png.pngtree.com/thumb_back/fw800/background/20260316/pngtree-futuristic-abstract-neural-network-with-glowing-data-streams-image_21586626.webp

Source: pngtree.com