Clase 2: Arquitecturas avanzadas para secuencias de largo aliento.

Vimos que las redes recurrentes resolvían un problema que el perceptrón multicapa no lograba, y era trabajar con datos secuenciales. Sin embargo, su arquitectura tenía un defecto y es que su dependencia del tiempo hace que el gradiente de la función de perdida explote o desaparezca si nos avanzamos mucho del punto de partida.

En la práctica, los modelos más efectivos son llamadas **redes neuronales controladas**, cuya arquitectura se basa en crear caminos en el tiempo cuyas derivadas que no explotan o desaparecen.

Las **unidades de fuga** permiten a la red acumular información en un largo periodo de tiempo.

$$\mu^{(t)} \leftarrow \alpha\,\mu^{(t-1)} + (1-\alpha)\,v^{(t)}$$

$\alpha \approx 1$ memoria larga

$\alpha \approx 0$ olvidadiza

Sin embargo, sería útil que la red, aprendiera a decidir cúando y qué tanto olvidará.

1. Long Short-Term Memory

En 1997, Hochreiter y Schmidhuber, introdujeron la idea de auto-lazos donde el gradiente fluye por largos períodos. En 2000, Gers y compañía, introdujeron la idea de pesar los lazos basados en el contexto

La unidad de olvido: $f_i^{(t)}$; controla cuánta información del estado anterior se mantiene.

$$f_i^{(t)} = \sigma\left(b_i^f + \sum_j U_{ij}^f x_j^{(t)} + \sum_j W_{ij}^f h_j^{(t-1)} \right)$$

La unidad de entrada externa $g_i^{(t)}$: Decide que nueva información se acumula en el estado de la celda.

$$g_i^{(t)} = \sigma\left(b_i^g + \sum_j U_{ij}^g x_j^{(t)} + \sum_j W_{ij}^g h_j^{(t-1)} \right)$$

El estado interno $s_i^{(t)} = f_i^{(t)} s_i^{(t-1)} + g_i^{(t)} \sigma\left(b_i + \sum_j U_{ij} x_j^{(t)} + \sum_j W_{ij} h_j^{(t-1)} \right)$ actualización que depende casi linealmente de $s_i^{(t-1)}$ y se adapta con la información que se guarda.

La unidad de salida $q_i^{(t)}$: filtra la información del estado que se presentará como salida visible.

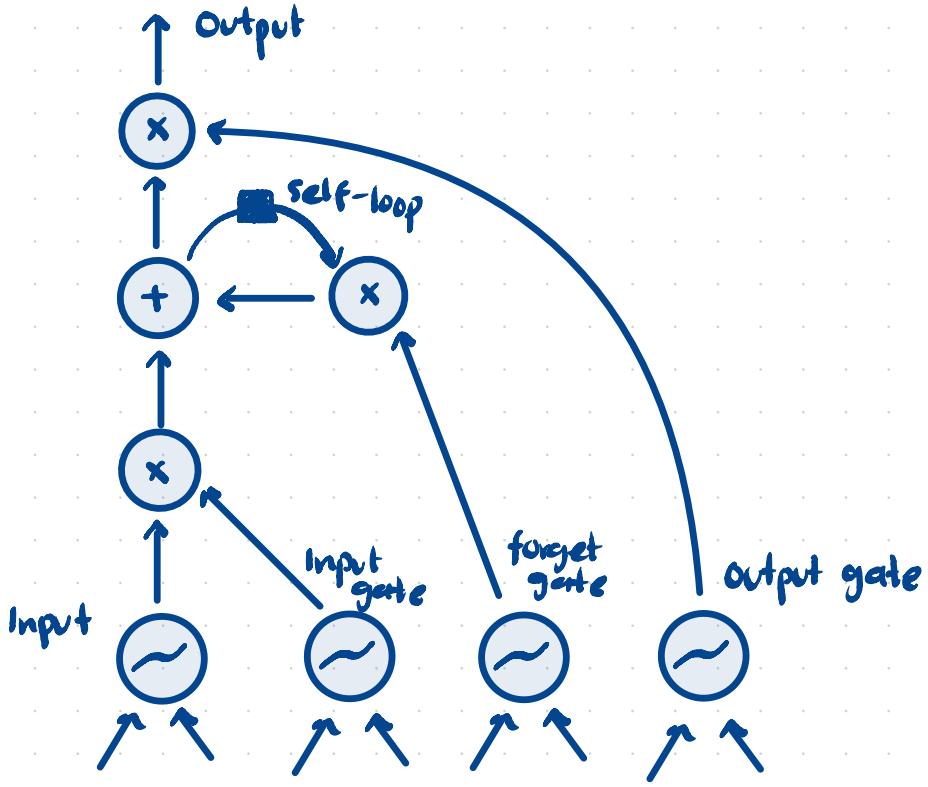
$$q_i^{(t)} = \sigma\left(b_i^o + \sum_j U_{ij}^o x_j^{(t)} + \sum_j W_{ij}^o h_j^{(t-1)} \right)$$

Actualización del estado oculto $h_i^{(t)}$

$$h_i^{(t)} = \tanh\left(s_i^{(t)} \right) \cdot q_i^{(t)}.$$

Las LSTM han mostrado su útidad en:

- Reconocimiento de escritura a mano (Graves, 2019)
- Reconocimiento de discurso (Graves, 2013-2014)
- Traducción maquina (Sutskever, 2014)
- Subtítulos de imágen (Kiros, 2014; Vinyals, 2014; Xu, 2015)



× representa multiplicación elemento a elemento.

+ representa la acumulación del estado

2. Otras RNR controladas.

- Todas las piezas de la arquitectura LSTM son necesarias?
- Hay otras arquitecturas que pueden ser diseñadas para permitir el control dinámico de la escala de tiempo y el olvido?

Entre 2014 y 2015, varios autores propusieron respuestas a las preguntas con las redes neuronales recurrentes controladas. La principal diferencia con LSTM es que una única compuerta controla simultáneamente los factores de olvido y actualización:

$$h_i^{(t)} = u_i^{(t-1)} h_i^{(t-1)} + (1 - u_i^{(t-1)}) \sigma\left(b_i + \sum_j U_{ij} x_j^{(t)} + \sum_j W_{ij} r_j^{(t-1)} h_j^{(t-1)} \right)$$

$$u_i^{(t)} = \sigma\left(b_i^u + \sum_j U_{ij}^u x_j^{(t)} + \sum_j W_{ij}^u h_j^{(t)} \right)$$

$$r_j^{(t)} = \sigma\left(b_i^r + \sum_j U_{ij}^r x_j^{(t)} + \sum_j W_{ij}^r h_j^{(t)} \right)$$