# La Revolución de la Atención y Arquitectura Transformer

## Desarrollo de Proyectos en Ingeniería Matemática - Sesión 03

Transitando de la recurrencia secuencial al procesamiento paralelo global en arquitecturas de Deep Learning profundo.

# I. Fase de Diagnóstico

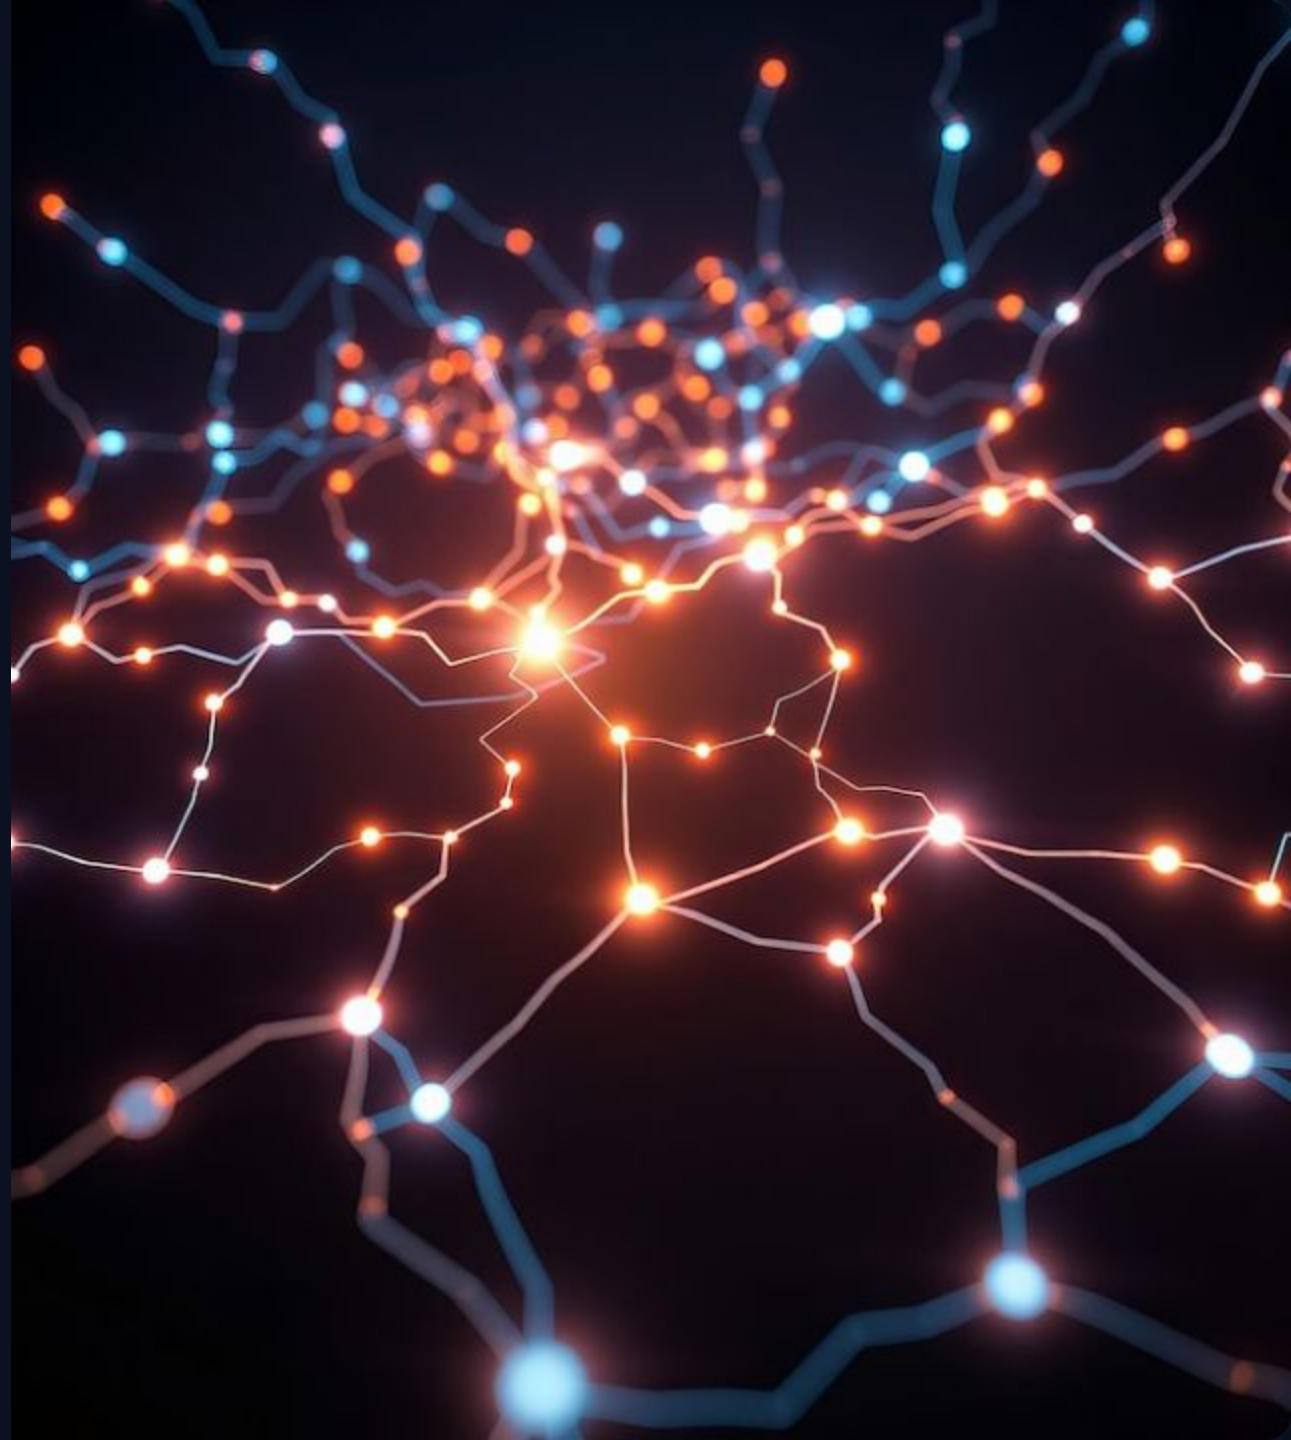
La "Muerte" de la Recurrencia y el Límite de las Redes Neuronales Clásicas

# El Cuello de Botella

Para conectar tokens distantes, la información atraviesa múltiples pasos en una RNN, sufriendo decaimiento exponencial (**Desvanecimiento del Gradiente**). Además, el cómputo secuencial impide la paralelización masiva en GPUs.

**Reto Fundamental:**

¿Cómo conectamos cualquier posición $i$ con la posición $j$ en $O(1)$ ?



# II. El Workshop Dinámico

Construcción Matemática del Mecanismo de Atención desde Cero

# Reto A: Búsqueda por Similitud

## Direccionamiento Suave

Definimos la atención como un **soft addressing**. En lugar de accesos binarios, calculamos el producto punto como métrica de similitud entre la consulta y el contexto. Aplicamos **Softmax** para normalizar y obtener una distribución de probabilidad. Al ser diferenciable, el modelo aprende la relevancia vía backpropagation.

$$\text{score}_i = \text{Query} \cdot \text{Key}_i$$

# Reto B: La Abstracción QKV



## Query (Q)

"¿Qué estoy buscando?" El token actual proyecta sus características para consultar la secuencia completa buscando contexto relevante.



## Key (K)

"¿Qué información ofrezco?" Cada token en la memoria genera una clave que será emparejada con las diferentes queries entrantes.



## Value (V)

"¿Qué contenido aporto?" Una vez establecida la relevancia (puntaje de atención), este es el vector real que se transportará.

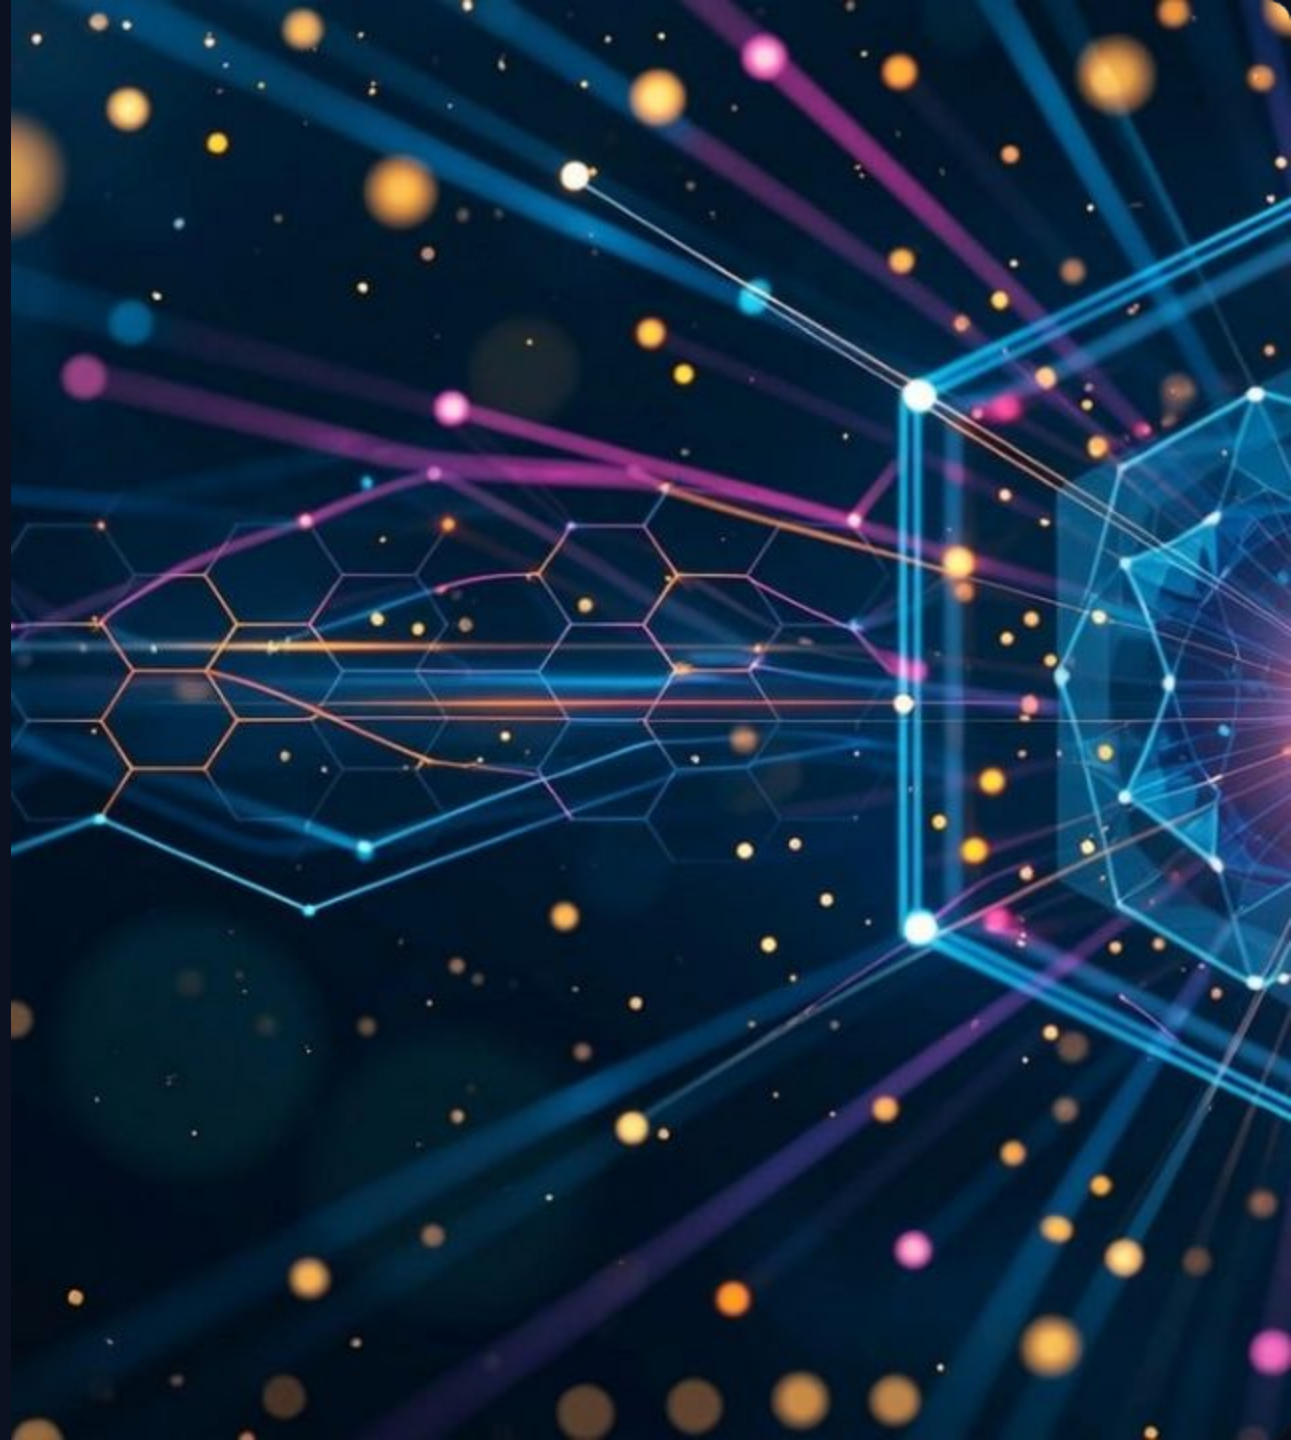
# III. Anatomía del Transformer

"Attention Is All You Need" - Eliminando por completo las CNNs y RNNs

# La Nueva Arquitectura

En "Attention Is All You Need", Vaswani et al. propusieron una arquitectura basada íntegramente en mecanismos de atención, descartando por completo la recurrencia algorítmica.

Esto permite paralelización total de los tensores y la captura de dependencias globales instantáneamente en cualquier tamaño de secuencia.



# Scaled Dot-Product Attention

## Análisis del Escalamiento

La clave de la ecuación radica en la división por $\sqrt{d_k}$ .

Sin este factor correctivo, en espacios vectoriales de alta dimensión, el producto punto crece masivamente. Esto empujará a la función Softmax hacia regiones extremadamente planas, resultando en **gradientes nulos**.

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

# MHA y Positional Encoding

## Multi-Head Attention (MHA)

Proyectar los tensores Q K V múltiples veces permite al modelo atender a diferentes **subespacios de representación** de forma simultánea.
Por ejemplo: un "Head" atiende a la estructura sintáctica, mientras otro abstrae dependencias puramente semánticas o entidades nombradas.

## Positional Encoding

Como hemos eliminado la recurrencia, la red carece de noción del orden secuencial (trata el texto como un conjunto).
La solución: inyectar tensores de **funciones sinusoidales y cosenoidales** para proporcionarle al sistema información posicional relativa y absoluta continua.

# IV. Construyendo el Transformer Block

## Conexión Residual

Implementamos

$$x + \text{Sublayer}(x)$$

Justificación: el gradiente salta directamente las capas, permitiendo entrenar sin problema arquitecturas de cientos de profundidades.

## Layer Normalization

A diferencia del Batch Norm, aquí normalizamos transversalmente las características de cada token. Esto unifica la escala del subespacio y estabiliza drásticamente las activaciones.

## Feed-Forward

Red Position-wise consistente en dos transformaciones lineales con activación ReLU en el medio, expandiendo y comprimiendo el espacio latente vector a vector.

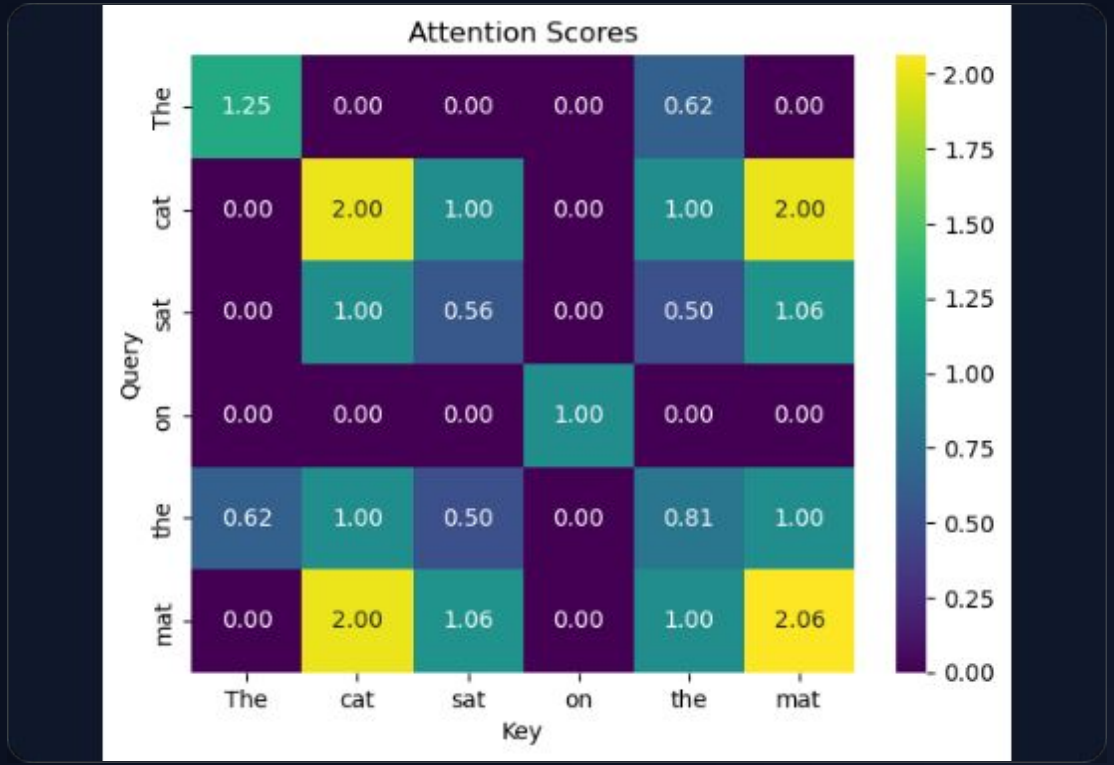
# V. Causalidad: El Decoder Autoregresivo

## Causal Masking

Para tareas generativas, implementamos una máscara causal en el bloque Decoder.

Durante el entrenamiento en paralelo, el modelo no debe hacer trampa "observando" tokens del futuro. La solución geométrica: asignamos en la matriz $-\infty$ tri-angular superior antes del Softmax.

Esto fuerza los pesos de atención al absoluto para posiciones futuras.



# VI. ¿Por qué la atención es todo lo que necesitas?

| Tipo de Capa | Complejidad por Capa | Camino de Dependencia Máximo |
|---|---|---|
| | $O$ | |
| | $O(n \cdot d^2)$ | $O(n)$ |
| | $n$ | |
| | $O(k \cdot n \cdot d^2)$ | $O(\log_k(n))$ |
| | . | |
| Red Recurrente (RNN) | $O(n^2 \cdot d)$ | $O(1)$ |
| | $d$ | $n$ |
| | | ) |
| | 2 | $O(1)$ |
| | ) | |

# Workshop Dinámico: PyTorch

Implementaremos Self-Attention desde los tensores base. Extraeremos y visualizaremos la matriz de pesos para analizar cómo interactúan los tokens y extraen semántica latente en nuestros datasets de análisis financiero.

# Image Sources



https://img.freepik.com/premium-photo/abstract-neural-network-illustration-futuristic-style_1143998-23768.jpg?semt=ais_hybrid&w=740&q=80

Source: www.freepik.com

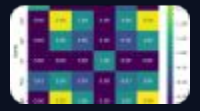
---



https://images.stockcake.com/public/4/4/8/448a9e4e-9294-40ab-99af-7268ef3f3f9d/ai-neural-network-stockcake.jpg

Source: stockcake.com

---



https://twiecki.io/blog/2024/01/04/self-attention_files/figure-html/cell-11-output-1.png

Source: twiecki.io

---



https://www.msudenver.edu/wp-content/uploads/2025/10/Python_ML_Overview_72.jpg

Source: www.msudenver.edu